TRƯỜNG ĐẠI HỌC KINH TẾ QUỐC DÂN

VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE

BÁO CÁO BÀI TẬP NHÓM - GIỮA KỲ 2

Học phần: Khoa học dữ liệu trong kinh tế và kinh doanh

Đề tài (Project 5):

Phân tích nguyên nhân và dự báo rủi ro nghỉ việc

IBM HR Analytics Employee Attrition & Performance

Giảng viên hướng dẫn: Trần Đức Minh

Nhóm sinh viên thực hiện

Họ và tên	**MSSV**
Nguyễn Thu Trang (Nhóm trưởng)	11248108
Hoàng Minh Ngọc	11247707
Tạ Bùi Vân Anh	11244614
Nguyễn Hoàng Hà Anh	11242469
Nguyễn Quang Huy	11244988

Hà Nội, 8 tháng 11 năm 2026

Bảng phân công công việc

Họ và tên	MSSV	Nhiệm vụ
Nguyễn Thu Trang	11248108	Định hướng bài toán & Giai đoạn 1: xác định câu hỏi nghiên cứu, mô tả và đánh giá dữ liệu; tổng hợp và biên tập báo cáo; quản lý kho GitHub.
Hoàng Minh Ngọc	11247707	Giai đoạn 2 – Làm sạch & Kỹ thuật đặc trưng: kiểm tra trùng lặp và ràng buộc logic, xử lý ngoại lệ, chiến lược điền thiếu, tạo đặc trưng, mã hóa và chuẩn hóa.
Tạ Bùi Vân Anh	11244614	Giai đoạn 3 – EDA & Kiểm định giả thuyết: trực quan hóa, kiểm định χ^2/Mann-Whitney, độ lớn hiệu ứng, hiệu chỉnh đa kiểm định.
Nguyễn Hoàng Hà Anh	11242469	Giai đoạn 3 – Mô hình hóa & Đánh giá: xây dựng pipeline, Logistic Regression, Random Forest, đánh giá và diễn giải mô hình.
Nguyễn Quang Huy	11244988	Giai đoạn 4 – Tác động & Khuyến nghị: ước tính chi phí, phân khúc ưu tiên, phân tích điểm hòa vốn, khuyến nghị.

Bảng 1: Phân công của nhóm

Lời cam đoan

Chúng tôi, Nguyễn Thu Trang, Hoàng Minh Ngọc, Tạ Bùi Vân Anh, Nguyễn Hoàng Hà Anh và Nguyễn Quang Huy, cam đoan đây là sản phẩm của nhóm. Các số liệu, bảng biểu, hình vẽ và đoạn mã trong báo cáo được tạo ra từ notebook của nhóm, trừ những nội dung đã được trích dẫn và ghi rõ nguồn. Chúng tôi hiểu rằng việc không ghi nguồn sẽ bị coi là đạo văn — một hình thức vi phạm liêm chính học thuật và sẽ bị xử lý theo quy định.

Nguyễn Thu Trang
Hoàng Minh Ngọc
Tạ Bùi Vân Anh
Nguyễn Hoàng Hà Anh
Nguyễn Quang Huy

Hà Nội, 8 tháng 11 năm 2026

Tóm tắt

Báo cáo phân tích vì sao nhân viên rời bỏ doanh nghiệp, dựa trên bộ dữ liệu IBM HR Analytics gồm 1.470 nhân viên và 35 thuộc tính, trong đó 237 người (16,1%) đã nghỉ việc. Quy trình gồm bốn giai đoạn: đánh giá dữ liệu, làm sạch, phân tích – kiểm định, và đánh giá tác động. Ở giai đoạn làm sạch, nhóm phát hiện ba vấn đề không thể thấy qua kiểm tra giá trị thiếu: một lỗi mã hóa có hệ thống ở 197 bản ghi, ba cột "Rate" mang giá trị ngẫu nhiên, và một biến gây nhiễu cấu trúc giữa tình trạng hôn nhân và cổ phiếu.

Bảy giả thuyết được kiểm định bằng χ^2 và Mann-Whitney U, có báo cáo độ mạnh liên hệ (Cramér's V) và hiệu chỉnh Bonferroni cho 28 kiểm định. Kết quả cho thấy làm thêm giờ là yếu tố mạnh nhất và kiểm soát được (rủi ro gấp 2,9 lần; 53% ở nhân viên cấp 1). Rủi ro cũng tập trung ở năm làm việc đầu tiên (34,9%). Ngược lại, đánh giá hiệu suất và mức tăng lương không phân biệt được người ở và người đi. Mô hình Logistic Regression đã tinh chỉnh đạt ROC-AUC 0,80 trên tập kiểm tra (0,85 khi kiểm định chéo); nhóm 20% nhân viên có điểm rủi ro cao nhất chứa 53% số người thực sự nghỉ. Khi bỏ giới tính, tuổi và hôn nhân, AUC gần như không đổi (0,79), và nhóm 20% rủi ro cao nhất vẫn chứa 55% số người nghỉ, nên mô hình có thể dùng mà không cần các thuộc tính nhạy cảm — nhưng chỉ nên là công cụ hỗ trợ có người rà soát. Tính điểm hòa vốn cho phân khúc làm thêm giờ ở cấp 1 cho thấy chương trình giữ chân chỉ có lãi khi giữ lại được ít nhất 17% số người sẽ nghỉ (khoảng 14/82 người), nên nhóm khuyến nghị ưu tiên can thiệp chi phí thấp và thí điểm có nhóm đối chứng.

Từ khóa: nghỉ việc, phân tích nhân sự, kiểm định giả thuyết, hồi quy logistic, biến gây nhiễu, điểm hòa vốn.

Mục lục

Bảng phân công công việc 1

Lời cam đoan 2

Tóm tắt 3

1 Giới thiệu 8

1.1 Bối cảnh kinh doanh 8

1.2 Câu hỏi nghiên cứu 8

1.3 Tổng quan phương pháp 8

2 Mô tả dữ liệu (Giai đoạn 1) 10

2.1 Tổng quan 10

2.2 Cấu trúc file 10

2.3 Đặc điểm chính của dữ liệu 11

3 Làm sạch dữ liệu (Giai đoạn 2) 12

3.1 Trùng lặp và cột không mang thông tin 12

3.2 Kiểm tra tính nhất quán logic 12

3.3 Ba cột “Rate”: kiểm tra ngữ nghĩa trước khi tin vào cột số 13

3.4 Ngoại lệ — phương pháp IQR 14

3.5 Giá trị thiếu: vì sao chọn Median thay vì Mean? 15

4 Kỹ thuật đặc trưng và mã hóa (Giai đoạn 2) 16

4.1 Lý do thiết kế 16

4.2 Bảng đặc trưng 16

4.3 Mã hóa và chuẩn hóa 17

4.4 Kiểm tra tương quan và đa cộng tuyến 18

5 Phân tích khám phá và kiểm định giả thuyết (Giai đoạn 3) 19

5.1 Mục đích và khung giả thuyết 19

5.2 Bức tranh tổng quan 20

5.3 H1 — Làm thêm giờ: yếu tố mạnh nhất và kiểm soát được 20

5.4 H2 — Thu nhập và công bằng nội bộ 21
5.5 H3 — Giai đoạn sự nghiệp: tuổi và thâm niên 22
5.6 H4 — Mức độ hài lòng và gắn kết 23
5.7 H5 — Cổ phiếu và tình trạng hôn nhân: một biến gây nhiễu cấu trúc 24
5.8 H6 và H7 — Vị trí, công tác và hiệu suất 24
5.9 Tổng hợp kiểm định với hiệu chỉnh đa kiểm định 25
5.10 Kết luận EDA 27
6 Mô hình dự báo rủi ro nghỉ việc (Giai đoạn 3) 28
6.1 Lựa chọn thuật toán 28
6.2 Hiệu năng mô hình 28
6.3 Ngưỡng phân loại và ma trận nhầm lẫn 29
6.4 Diễn giải mô hình 30
6.5 Kiểm tra khi bỏ thuộc tính nhạy cảm 32
7 Đánh giá tác động và khuyến nghị (Giai đoạn 4) 33
7.1 Trả lời câu hỏi nghiên cứu 33
7.2 Quy mô tác động tài chính 33
7.3 Phân khúc ưu tiên 33
7.4 Điểm hòa vốn của chương trình giữ chân 33
7.5 Chiến lược theo phân khúc 34
8 Kết luận 36
8.1 Tóm tắt 36
8.2 Giới hạn 36
8.3 Hướng mở rộng 37
Tài liệu tham khảo 38

Danh mục hình

Hình 1: Phân phối biến mục tiêu Attrition: 1.233 ở lại (83,9%) và 237 nghỉ việc (16,1%).....11
Hình 2: Bảng chéo NumCompaniesWorked × số năm làm ở nơi khác (tỷ lệ theo hàng) 13
Hình 3: Lương giờ quy đổi và MonthlyRate đều không liên hệ với lương tháng thực tế 14
Hình 4: Boxplot theo nhóm Attrition: ngoại lệ chủ yếu ở phía giá trị cao và thuộc nhóm ở lại 14
Hình 5: Ma trận tương quan Spearman (nửa dưới) giữa các biến số và biến mục tiêu 18
Hình 6: Tỷ lệ nghỉ việc theo sáu biến phân loại; cột cam là nhóm cao hơn trung bình 16,1% 20
Hình 7: Tỷ lệ nghỉ theo OverTime kết hợp cấp bậc (trái) và nhóm tuổi (phải); mỗi ô ghi kèm cỡ mẫu 20
Hình 8: Lương theo cấp bậc và Attrition (trái); tỷ lệ nghỉ theo ngũ phân vị lương tương đối trong cùng cấp (phải).....21
Hình 9: Tỷ lệ nghỉ theo nhóm tuổi và số năm tại công ty, kèm cỡ mẫu từng nhóm; đường đứt là tỷ lệ trung bình.....22
Hình 10: Tỷ lệ nghỉ việc theo từng mức của năm thang khảo sát (1 = thấp nhất).....23
Hình 11: Bảng chéo MaritalStatus × StockOptionLevel: số nhân viên (trái) và tỷ lệ nghỉ kèm cỡ mẫu (phải); * = ô có n < 30 24
Hình 12: Tỷ lệ nghỉ theo % tăng lương (trái) và theo mức đánh giá hiệu suất (phải).....24
Hình 13: Đường ROC, Precision–Recall và Cumulative Gains trên tập kiểm tra (294 nhân viên).....29
Hình 14: Odds ratio của Logistic Regression: cho mỗi +1 độ lệch chuẩn (biến số) hoặc so với nhóm tham chiếu (biến one-hot).....30
Hình 15: Mức độ quan trọng của biến trong Random Forest (feature_importances_, mức giảm Gini trung bình) 32

Danh mục bảng

Bảng 1: Phân công của nhóm 1
Bảng 2: Cấu trúc file và vai trò trong phân tích 10
Bảng 3: Từ điển dữ liệu — phân nhóm theo bản chất, không chỉ theo kiểu dữ liệu máy đọc 10
Bảng 4: Tổng hợp các quyết định làm sạch dữ liệu 12
Bảng 5: Kiểm tra sáu ràng buộc nghiệp vụ 13
Bảng 6: Kết quả phát hiện ngoại lệ bằng IQR 14
Bảng 7: Từ điển đặc trưng ((*) = đóng góp phân tích của nhóm) 16
Bảng 8: Quyết định mã hóa và chuẩn hóa 17
Bảng 9: Khung giả thuyết và kết luận (chi tiết ở các mục 5.2–5.8) 19
Bảng 10: So sánh lương trong từng cấp bậc (Mann-Whitney U, hiệu chỉnh Bonferroni) 21
Bảng 11: Tỷ lệ nghỉ ở hai đầu thang khảo sát; kiểm định χ^2 trên cả 4 mức và χ^2 2×2 so sánh mức 1 với các mức còn lại 23
Bảng 12: Tổng hợp kiểm định, sắp xếp theo p-value (rút gọn; bảng đầy đủ 28 dòng trong notebook mục 3.9) 26
Bảng 13: So sánh mô hình đã tinh chỉnh (Recall/Precision/F1 ở ngưỡng 0,5 cho lớp "Nghỉ việc") 28
Bảng 14: Ma trận nhầm lẫn trên tập test ở ngưỡng 0,5 (Logistic, không dùng thuộc tính nhạy cảm) 29
Bảng 15: Odds ratio từ Logit không phạt, mô hình rút gọn (VIF ≤ 7,1); toàn bộ 1.470 nhân viên 31
Bảng 16: Ước tính chi phí do nghỉ việc 33
Bảng 17: Các phân khúc rủi ro cao (lift = tỷ lệ nghỉ / tỷ lệ trung bình; các phân khúc có thể giao nhau) 33
Bảng 18: Điểm hòa vốn của chương trình giữ chân cho phân khúc "OverTime + cấp 1" 34
Bảng 19: Tổng hợp chiến lược và KPI, xếp theo mức ưu tiên 35

1 Giới thiệu

1.1 Bối cảnh kinh doanh

Nghỉ việc là một chi phí lớn nhưng thường bị đánh giá thấp. Theo Gallup, thay thế một nhân viên tốn từ một nửa đến hai lần lương năm của người đó, chưa kể mất kiến thức, giảm năng suất của nhóm và chi phí đào tạo người mới. Gallup cũng ghi nhận khoảng một nửa số người nghỉ tự nguyện cho rằng quản lý hoặc tổ chức đã có thể giữ họ lại. Nói cách khác, một phần lớn nghỉ việc có thể phòng ngừa — nếu doanh nghiệp biết *ai* có nguy cơ và *vì sao*.

Nhiều doanh nghiệp vẫn phản ứng với nghỉ việc một cách bị động: chỉ biết khi nhân viên nộp đơn. Dữ liệu nhân sự sẵn có (cấp bậc, thu nhập, giờ làm, khảo sát hài lòng) cho phép chuyển sang cách tiếp cận chủ động: nhận diện sớm nhóm rủi ro và tập trung nguồn lực giữ chân vào đúng chỗ.

1.2 Câu hỏi nghiên cứu

Câu hỏi trung tâm của báo cáo là: *Những yếu tố nào gắn với quyết định nghỉ việc của nhân viên, và doanh nghiệp nên can thiệp vào nhóm nào, bằng biện pháp gì, để chi phí bỏ ra có lãi?* Câu hỏi được tách thành ba câu hỏi con:

- Q1 — Nguyên nhân: yếu tố nào có liên hệ có ý nghĩa thống kê với nghỉ việc, và độ lớn ra sao?
- Q2 — Dự báo: có thể xếp hạng rủi ro từng nhân viên đủ tốt để ưu tiên can thiệp không, mà không dùng thuộc tính nhạy cảm?
- Q3 — Tác động: chương trình giữ chân cần hiệu quả đến mức nào thì mới hòa vốn?

1.3 Tổng quan phương pháp

Báo cáo đi theo bốn giai đoạn của đề bài, được triển khai thành sáu bước trong notebook:

- Thu thập & đánh giá dữ liệu (Giai đoạn 1, Chương 2) — mô tả nguồn, cấu trúc, kiểu dữ liệu, giá trị thiếu, mất cân bằng lớp.
- Làm sạch dữ liệu (Giai đoạn 2, Chương 3) — trùng lặp, ràng buộc logic, ngữ nghĩa cột, ngoại lệ, chiến lược điền thiếu.
- Kỹ thuật đặc trưng & mã hóa (Giai đoạn 2, Chương 4) — tạo biến nghiệp vụ, chọn kỹ thuật mã hóa và chuẩn hóa có lý do.
- Phân tích & kiểm định giả thuyết (Giai đoạn 3, Chương 5) — bảy giả thuyết, χ^2, Mann-Whitney U, Cramér's V, hiệu chỉnh Bonferroni.

- Mô hình dự báo rủi ro (Giai đoạn 3, Chương 6) — Logistic Regression và Random Forest theo Chương 11 giáo trình; kiểm tra hệ số bằng VIF và Logit; kiểm tra khi bỏ thuộc tính nhạy cảm.
- Đánh giá tác động & khuyến nghị (Giai đoạn 4, Chương 7–8) — chi phí, phân khúc ưu tiên, điểm hòa vốn, giới hạn và hướng mở rộng.

Toàn bộ mã nguồn nằm trong notebook `IBM_HR_Attrition_Analysis.ipynb`, chạy được bằng *Run all* trên Google Colab, lưu tại GitHub: https://github.com/trangthu171106/ibm-hr-attrition-analysis.

2 Mô tả dữ liệu (Giai đoạn 1)

2.1 Tổng quan

Bộ dữ liệu *IBM HR Analytics Employee Attrition & Performance* được các nhà khoa học dữ liệu của IBM tạo ra để mô phỏng hồ sơ nhân sự (dữ liệu giả lập, không phải nhân viên thật) và được chia sẻ trên Kaggle. Dữ liệu gồm 1.470 quan sát và 35 thuộc tính: 26 kiểu số và 9 kiểu chữ. Biến mục tiêu `Attrition` (Yes/No) cho biết nhân viên đã nghỉ việc hay chưa. Bài toán vì vậy có hai lớp: phân tích nguyên nhân và phân loại nhị phân.

2.2 Cấu trúc file

Dữ liệu gồm một file duy nhất nên không cần ghép bảng qua khóa ngoại. Nhóm vẫn kiểm tra `EmployeeNumber` là khóa chính duy nhất (đạt). Notebook ưu tiên đọc file cục bộ trong repo; nếu không có, notebook tự tải bản gốc từ kho GitHub của IBM.

File	Khóa chính	Số dòng × cột	Vai trò trong phân tích
`WA_Fn-UseC_-HR-Employee-Attrition.csv`	`EmployeeNumber`	1.470 × 35	Nguồn duy nhất — mọi phân tích và đặc trưng đều suy ra từ file này

Bảng 2: Cấu trúc file và vai trò trong phân tích

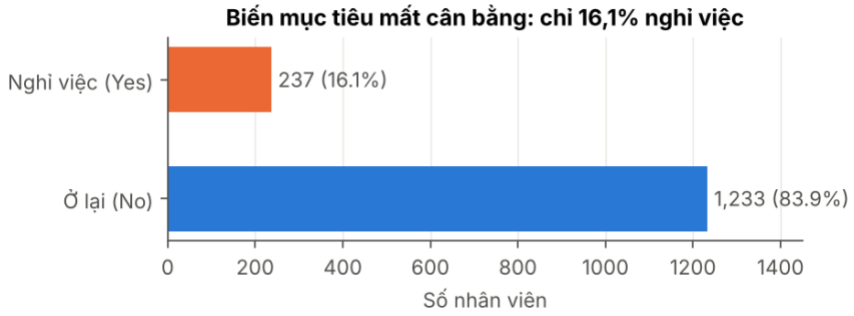
Nhóm	Thuộc tính	Bản chất / mã hóa
Nhân khẩu học	Age, Gender, MaritalStatus, DistanceFromHome	Số liên tục và danh nghĩa
Công việc	Department, JobRole, JobLevel (1–5), BusinessTravel, OverTime	Danh nghĩa; JobLevel và BusinessTravel có thứ tự
Thu nhập	MonthlyIncome, PercentSalaryHike, StockOptionLevel (0–3)	Liên tục, lệch phải; StockOption thứ bậc
Khảo sát (1–4)	EnvironmentSatisfaction, JobSatisfaction, RelationshipSatisfaction, JobInvolvement, WorkLifeBalance	Thang Likert thứ bậc: 1 = thấp … 4 = rất cao
Hiệu suất	PerformanceRating (thang 1–4), TrainingTimesLastYear	Thứ bậc / đếm
Thâm niên	TotalWorkingYears, NumCompaniesWorked, YearsAtCompany, YearsInCurrentRole, YearsSinceLastPromotion, YearsWithCurrManager	Đếm theo năm, lệch phải
Chưa rõ nghĩa	DailyRate, HourlyRate, MonthlyRate	Không có mô tả — kiểm tra ở mục 3.3
Kỹ thuật	EmployeeNumber, EmployeeCount, Over18, StandardHours	ID và cột hằng

Bảng 3: Từ điển dữ liệu — phân nhóm theo bản chất, không chỉ theo kiểu dữ liệu máy đọc

2.3 Đặc điểm chính của dữ liệu

Không có giá trị thiếu (0 trên 51.450 ô) và không có dòng trùng. Tuy nhiên, "sạch về hình thức" chưa có nghĩa là "sạch về nội dung". Nhóm ghi nhận bốn đặc điểm ảnh hưởng trực tiếp đến cách xử lý ở các chương sau:

- Cột hằng: `EmployeeCount` = 1, `Over18` = Y, `StandardHours` = 80 cho mọi nhân viên — không mang thông tin.
- Số nhưng không phải số đo: mười cột kiểu số thực chất là thang thứ bậc (Education, JobLevel, các thang khảo sát…). Tính trung bình trên chúng dễ dẫn đến hiểu sai.
- Cột chưa rõ nghĩa: `DailyRate`, `HourlyRate`, `MonthlyRate` không có mô tả.
- Mất cân bằng lớp: tỷ lệ 5,2 : 1 (Hình 1). Mô hình "luôn đoán No" đạt Accuracy 83,9% mà không phát hiện được ai, nên Accuracy không được dùng làm thước đo chính.



Hình 1: Phân phối biến mục tiêu Attrition: 1.233 ở lại (83,9%) và 237 nghỉ việc (16,1%)

3 Làm sạch dữ liệu (Giai đoạn 2)

Mọi quyết định làm sạch tuân theo một nguyên tắc: *giữ toàn vẹn phân tích mà không vứt bỏ tín hiệu hành vi có thật*. Mỗi quyết định đều có lý do được ghi lại. Trước làm sạch, dữ liệu có 1.470 dòng × 35 cột; sau làm sạch còn 1.470 dòng × 31 thuộc tính + biến mục tiêu. Không dòng nào bị xóa. Bảng 4 tổng hợp các quyết định; các mục 3.1–3.5 trình bày bằng chứng.

Vấn đề	**Quyết định**	**Lý do**
3 cột hằng (EmployeeCount, Over18, StandardHours)	Loại bỏ	Một giá trị duy nhất, không có khả năng phân biệt
EmployeeNumber	Loại khỏi tập đặc trưng	Chỉ là mã định danh; đã xác nhận duy nhất
Trùng lặp (toàn dòng; nội dung khi bỏ ID)	Không có — không xử lý	Kiểm tra cả hai cấp để bắt trường hợp một người bị nhập hai lần với hai mã
197 bản ghi NumCompaniesWorked = 0 mâu thuẫn với thâm niên	Giữ nguyên, gắn cờ NCW_inconsistent	Lỗi mã hóa có hệ thống; không biết giá trị đúng nên không tự sửa
DailyRate, HourlyRate, MonthlyRate	Loại khỏi mô hình, giữ để mô tả	Tương quan ≈ 0 với lương thực tế; nhiều khả năng là số ngẫu nhiên
Ngoại lệ IQR (lương, thâm niên)	Giữ, không cắt ngưỡng	Là quản lý cấp 4–5 thật; xóa sẽ làm lệch tỷ lệ nghỉ
Biến lệch phải (12 biến, skew > 0,75)	log1p trước khi chuẩn hóa	Giảm ảnh hưởng đuôi phải cho mô hình tuyến tính
Giá trị thiếu (hiện 0)	SimpleImputer(median) trong pipeline	Phân phối lệch; median sai số thấp hơn mean 36%
Mất cân bằng lớp 5,2 : 1	Chia tập phân tầng; class_weight='balanced'	Giữ tỷ lệ 16% ở mọi tập; tránh mô hình bỏ qua lớp thiểu số

Bảng 4: Tổng hợp các quyết định làm sạch dữ liệu

3.1 Trùng lặp và cột không mang thông tin

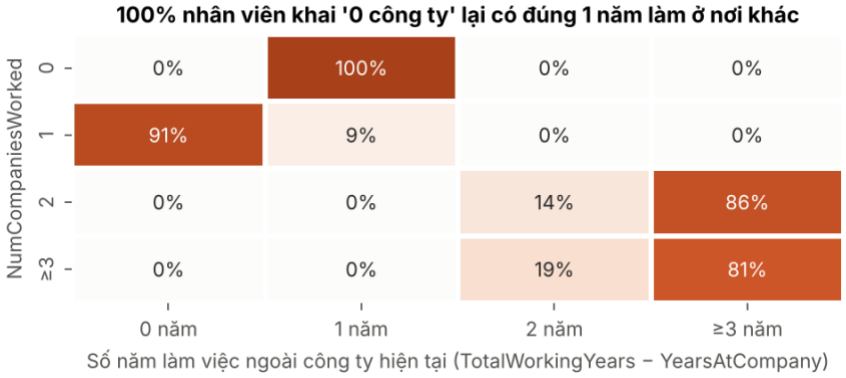
Nhóm kiểm tra trùng lặp ở hai cấp: trùng toàn bộ dòng (0) và trùng nội dung khi bỏ mã nhân viên (0). Cấp thứ hai quan trọng hơn vì một người có thể bị nhập hai lần với hai mã khác nhau. Ba cột hằng và cột ID bị loại vì không có khả năng phân biệt.

3.2 Kiểm tra tính nhất quán logic

Dữ liệu không thiếu nhưng có thể mâu thuẫn nội tại. Nhóm đặt sáu quy tắc nghiệp vụ mà một hồ sơ hợp lệ phải thỏa (Bảng 5).

Quy tắc nghiệp vụ	Số bản ghi vi phạm
YearsAtCompany ≤ TotalWorkingYears	0
YearsInCurrentRole ≤ YearsAtCompany	0
YearsWithCurrManager ≤ YearsAtCompany	0
YearsSinceLastPromotion ≤ YearsAtCompany	0
Age − TotalWorkingYears ≥ 18 (bắt đầu đi làm từ 18 tuổi)	0
NumCompaniesWorked = 0 ⇒ TotalWorkingYears = YearsAtCompany	197 (13,4%)

Bảng 5: Kiểm tra sáu ràng buộc nghiệp vụ

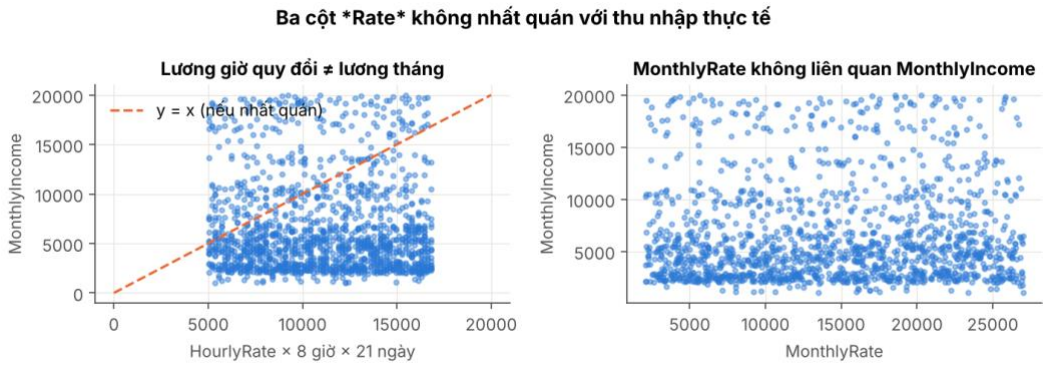


Hình 2: Bảng chéo NumCompaniesWorked × số năm làm ở nơi khác (tỷ lệ theo hàng)

Với `NumCompaniesWorked = 1`, 91% bản ghi có tổng năm làm bằng số năm tại công ty, nghĩa là biến này đếm cả công ty hiện tại. Theo logic đó, giá trị 0 là bất khả. Cả 197 bản ghi mức 0 đều lệch *đúng 1 năm*. Một mẫu hình đều tuyệt đối như vậy không giống lỗi nhập liệu ngẫu nhiên mà giống lỗi mã hóa có hệ thống của bộ sinh dữ liệu. Nhóm không tự sửa vì không biết giá trị đúng là 1 hay 2, mà gắn cờ `NCW_inconsistent` và ghi nhận ở phần giới hạn. Rủi ro của quyết định thấp vì biến này không có ý nghĩa thống kê với Attrition (Bảng 12).

3.3 Ba cột "Rate": kiểm tra ngữ nghĩa trước khi tin vào cột số

Nếu `HourlyRate` là lương giờ thì lương giờ × 8 giờ × 21 ngày phải xấp xỉ `MonthlyIncome`. Hình 3 cho thấy điều đó sai hoàn toàn: tương quan Spearman của ba cột với MonthlyIncome lần lượt là 0,016; −0,020 và 0,054.



Hình 3: Lương giờ quy đổi và MonthlyRate đều không liên hệ với lương tháng thực tế

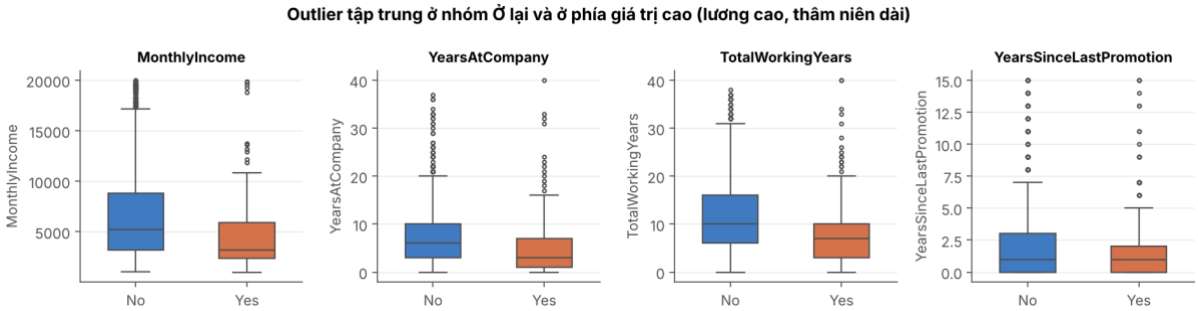
Ba cột này nhiều khả năng là số ngẫu nhiên nên bị loại khỏi mô hình. `DailyRate` có p = 0,029 khi so hai nhóm, nhưng nhóm không coi đây là bằng chứng: biến không có nghĩa rõ ràng, hai cột cùng loại không có ý nghĩa, và với ba kiểm định thì ngưỡng Bonferroni là 0,017. Đây là ví dụ điển hình của dương tính giả do kiểm định nhiều lần.

3.4 Ngoại lệ — phương pháp IQR

Ngoại lệ được xác định là giá trị nằm ngoài khoảng [Q1 − 1,5·IQR; Q3 + 1,5·IQR]. Do cận dưới đều âm, mọi ngoại lệ đều nằm ở phía giá trị cao.

Biến	Cận trên	Số ngoại lệ	%	Skewness	Mean	Median
MonthlyIncome	16.581	114	7,8	1,37	6.503	4.919
YearsSinceLastPromotion	7,5	107	7,3	1,98	2,2	1
YearsAtCompany	18	104	7,1	1,76	7,0	5
TotalWorkingYears	28,5	63	4,3	1,12	11,3	10
NumCompaniesWorked	8,5	52	3,5	1,03	2,7	2
YearsInCurrentRole	14,5	21	1,4	0,92	4,2	3
Age; DistanceFromHome	—	0	0	0,41; 0,96	—	—

Bảng 6: Kết quả phát hiện ngoại lệ bằng IQR



Hình 4: Boxplot theo nhóm Attrition: ngoại lệ chủ yếu ở phía giá trị cao và thuộc nhóm ở lại

Cả 114 ngoại lệ thu nhập đều thuộc JobLevel 4 (45 người) và 5 (69 người), tức là quản lý cấp cao — giá trị hợp lệ, không phải lỗi. Nếu xóa, nhóm mất 7,8% mẫu và bỏ đi đúng phân

khúc có tỷ lệ nghỉ thấp nhất (4,7–7,2%), khiến tỷ lệ nghỉ chung bị thổi phồng. Vì vậy nhóm không xóa và không cắt ngưỡng. Vấn đề thật là *độ lệch*, được xử lý bằng log1p cho 12 biến có skewness > 0,75 (ví dụ MonthlyIncome giảm từ 1,37 xuống 0,29). Random Forest chia nhánh theo ngưỡng nên không chịu ảnh hưởng của ngoại lệ.

3.5 Giá trị thiếu: vì sao chọn Median thay vì Mean?

Dữ liệu hiện không thiếu, nhưng pipeline vẫn đặt `SimpleImputer(strategy="median")` để chạy an toàn với dữ liệu mới. Lý do được kiểm chứng bằng số liệu: MonthlyIncome lệch phải (skew = 1,37), mean = 6.503 cao hơn median = 4.919, và 66,5% nhân viên có lương thấp hơn mean. Nhóm làm một thí nghiệm nhỏ: xóa ngẫu nhiên 10% giá trị lương rồi điền lại. Sai số tuyệt đối trung vị khi điền bằng mean là 3.319; khi điền bằng median là 2.123 — thấp hơn 36%.

4 Kỹ thuật đặc trưng và mã hóa (Giai đoạn 2)

4.1 Lý do thiết kế

Mỗi đặc trưng mới được tạo để đo một khía cạnh mà dữ liệu gốc chỉ thể hiện gián tiếp. Hai đặc trưng là đóng góp phân tích chính của nhóm:

- RelPayInLevel — MonthlyIncome tương quan 0,92 với JobLevel, nên lương tuyệt đối chủ yếu phản ánh cấp bậc. Chia lương cho trung vị lương cùng cấp tách được phần "được trả thấp hơn đồng cấp", tức là đo trực tiếp *công bằng nội bộ* theo thuyết công bằng của Adams.
- NCW_inconsistent — cờ đánh dấu 197 bản ghi lỗi, cho phép mô hình tách riêng nhóm này thay vì xem giá trị lỗi như giá trị thật.

4.2 Bảng đặc trưng

Đặc trưng	**Nhóm**	**Công thức**	**Ý nghĩa kinh doanh**
RelPayInLevel (*)	Thu nhập	MonthlyIncome / median(MonthlyIncome | JobLevel)	Trả cao hay thấp so với đồng cấp
YearsPerCompany	Sự nghiệp	TotalWorkingYears / (NumCompaniesWorked + 1)	Mức gắn bó trung bình với mỗi công ty cũ — xu hướng "nhảy việc"
PromotionStagnation	Sự nghiệp	YearsSinceLastPromotion / (YearsAtCompany + 1)	Mức độ "dậm chân tại chỗ"
SatisfactionIndex	Khảo sát	Trung bình 4 thang hài lòng (1–4)	Mức hài lòng tổng hợp; chỉ dùng để mô tả, không đưa vào mô hình vì trùng thông tin với 4 thang gốc
NCW_inconsistent (*)	Chất lượng	1 nếu NumCompaniesWorked = 0	Cờ lỗi dữ liệu
5 cờ ..._is1 (*)	Khảo sát	1 nếu thang khảo sát = 1 (mức thấp nhất)	Bắt hiệu ứng ngưỡng ở mức hài lòng thấp nhất (mục 5.6)
OverTime_bin, Gender_bin	Mã hóa	Yes/Male = 1, còn lại = 0	Biến nhị phân
BusinessTravel_ord	Mã hóa	Non = 0, Rarely = 1, Frequently = 2	Tần suất công tác có thứ tự
AgeGroup, TenureGroup	EDA	Chia khoảng tuổi / thâm niên	Chỉ dùng cho trực quan hóa

Bảng 7: Từ điển đặc trưng ((*) = đóng góp phân tích của nhóm)

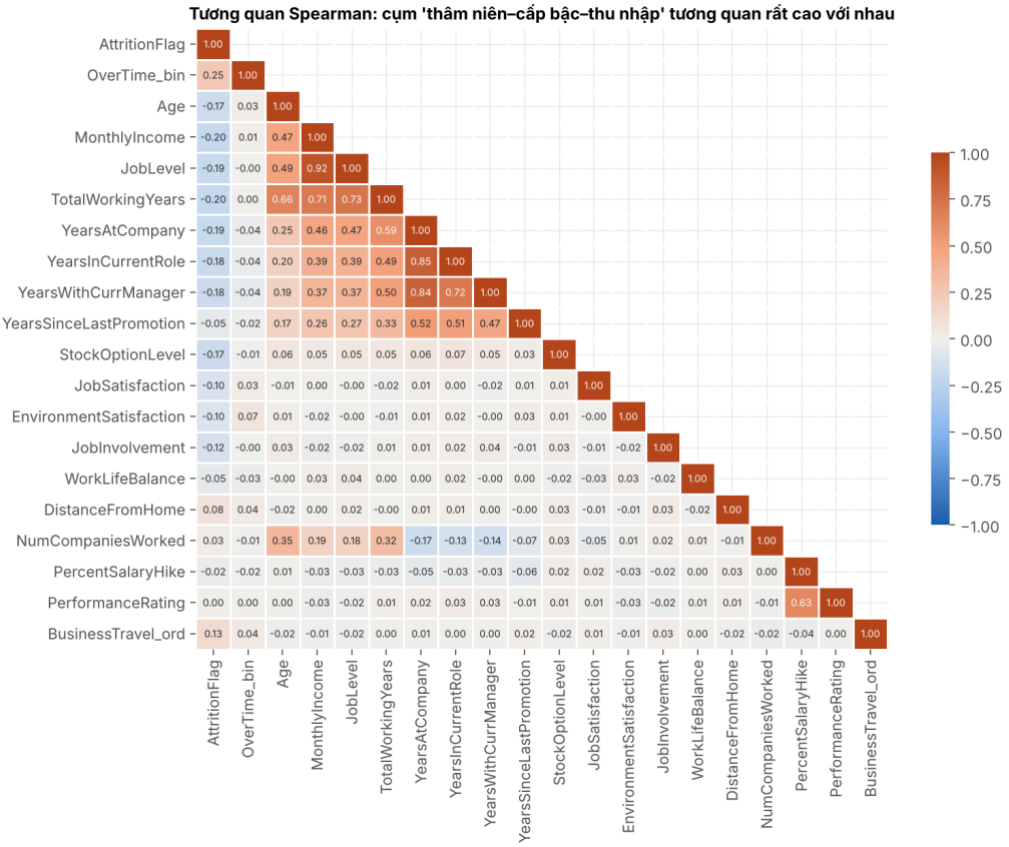
4.3 Mã hóa và chuẩn hóa

Nhóm biến	Kỹ thuật	Lý do lựa chọn
OverTime, Gender	Map 0/1	Biến nhị phân, không cần tạo thêm cột
BusinessTravel	Ordinal 0/1/2	Thứ tự tự nhiên; tỷ lệ nghỉ tăng đơn điệu 8% → 15% → 25%
Department, JobRole, EducationField, MaritalStatus	One-Hot (drop='first' cho Logistic)	Không có thứ tự. Label Encoding áp đặt thứ tự giả (VD Sales > HR). Bỏ một cột để tránh đa cộng tuyến hoàn hảo
JobLevel, Education, StockOptionLevel	Giữ dạng số	Bảo toàn thứ tự, ít tham số hơn One-Hot
5 thang khảo sát 1–4	Giữ dạng số + thêm cờ "mức = 1"	Rủi ro tập trung ở mức thấp nhất và WorkLifeBalance không đơn điệu (mục 5.6). Chỉ dùng dạng số sẽ ép quan hệ thành tuyến tính
12 biến lệch phải	log1p → StandardScaler	Giảm đuôi phải; Logistic có phạt L2 cần các biến cùng thang đo để hệ số so sánh được
Mô hình Random Forest	Không chuẩn hóa	Mô hình cây không bị ảnh hưởng bởi biến đổi đơn điệu

Bảng 8: Quyết định mã hóa và chuẩn hóa

Nhóm không dùng MinMaxScaler vì phương pháp này nhạy với ngoại lệ — vốn đã được giữ lại ở mục 3.4. Toàn bộ các bước nằm trong `Pipeline` của scikit-learn và chỉ "học" từ tập huấn luyện, nhờ đó tránh rò rỉ dữ liệu sang tập kiểm tra.

4.4 Kiểm tra tương quan và đa cộng tuyến



Hình 5: Ma trận tương quan Spearman (nửa dưới) giữa các biến số và biến mục tiêu

Nhóm dùng Spearman thay vì Pearson vì nhiều biến là thứ bậc và phân phối lệch. Có hai nhận xét. (1) Không biến nào tương quan với Attrition quá |0,25|: nghỉ việc là kết quả của nhiều yếu tố yếu cộng dồn, không có một nguyên nhân duy nhất — đây là lý do cần mô hình đa biến ở Chương 6. (2) Có một cụm đa cộng tuyến mạnh: JobLevel–MonthlyIncome (ρ = 0,92), YearsInCurrentRole–YearsAtCompany (0,85), YearsWithCurrManager–YearsAtCompany (0,84). Tương quan từng cặp chỉ là dấu hiệu ban đầu; mức độ đa cộng tuyến thật sự được đo bằng VIF ở mục 6.4. Mô hình dự báo dùng phạt L2 (hệ số C chọn bằng GridSearchCV) để ổn định hệ số, còn phần diễn giải dùng một mô hình rút gọn đã loại các biến có VIF cao.

5 Phân tích khám phá và kiểm định giả thuyết (Giai đoạn 3)

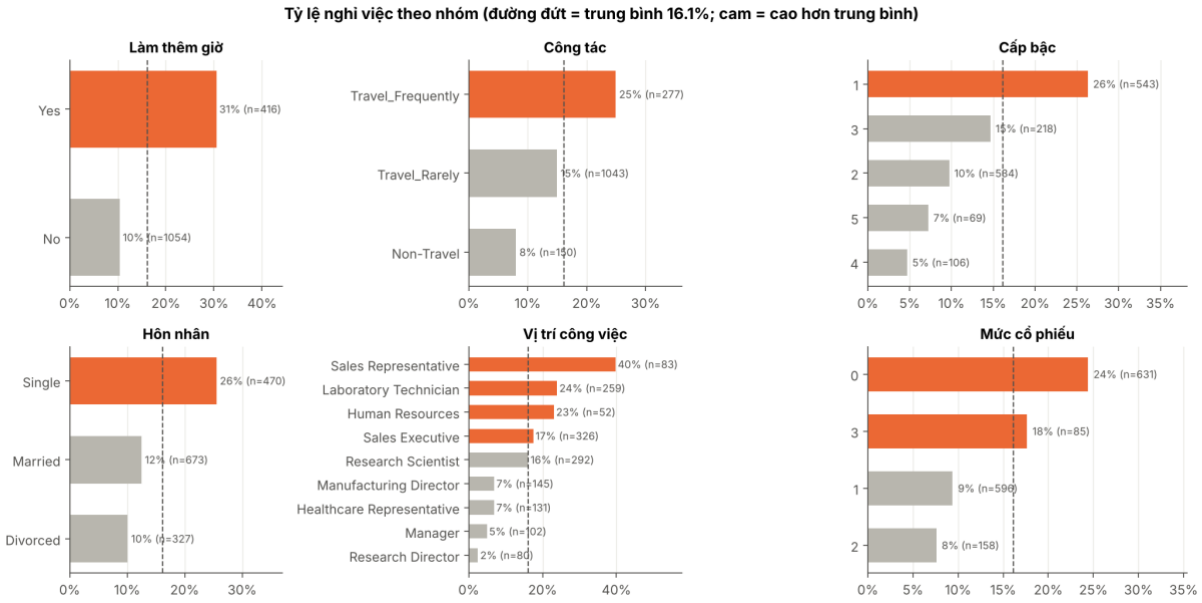
5.1 Mục đích và khung giả thuyết

Mỗi giả thuyết gắn với một cơ sở lý thuyết nhân sự và một kiểm định phù hợp với kiểu dữ liệu. Biến phân loại dùng χ^2 độc lập, đo độ lớn bằng Cramér's V. Biến số dùng Mann-Whitney U thay vì t-test vì lương và thâm niên lệch phải; nhóm so sánh trung vị của hai nhóm. Nhóm báo cáo thêm Cramér's V vì với n = 1.470, ngay cả liên hệ rất yếu cũng có thể cho $p < 0,05$. Với mỗi giả thuyết, giả thuyết không (H0) là "không có liên hệ với nghỉ việc". Bảng 9 ghi "được ủng hộ" khi bác bỏ được H0 ở mức 5%, và "không được ủng hộ" khi không bác bỏ được H0; trường hợp sau không chứng minh hai nhóm giống nhau, mà chỉ cho thấy dữ liệu không đủ bằng chứng về khác biệt.

#	Giả thuyết	Cơ sở	Kết quả
H1	Làm thêm giờ làm tăng nghỉ việc	Kiệt sức (burnout)	Được ủng hộ — hiệu ứng mạnh nhất
H2	Người nghỉ có thu nhập thấp hơn, kể cả trong cùng cấp bậc	Thuyết công bằng (Adams)	Được ủng hộ một phần — chỉ vững ở cấp 1
H3	Rủi ro cao nhất ở đầu sự nghiệp/đầu nhiệm kỳ	Chi phí chuyển việc thấp khi trẻ	Được ủng hộ
H4	Hài lòng càng thấp, nghỉ việc càng cao	Thuyết hai nhân tố (Herzberg)	Được ủng hộ có điều kiện — ngưỡng ở mức 1
H5	Cổ phiếu dài hạn giữ chân nhân viên	"Còng tay vàng"	Được ủng hộ sau phân tầng; có biến gây nhiễu
H6	Vị trí và tần suất công tác ảnh hưởng nghỉ việc	Đặc thù công việc	Được ủng hộ
H7	Hiệu suất/tăng lương cao giúp giữ người	Trả lương theo hiệu suất	Không được ủng hộ — không đủ bằng chứng về khác biệt

Bảng 9: Khung giả thuyết và kết luận (chi tiết ở các mục 5.2–5.8)

5.2 Bức tranh tổng quan

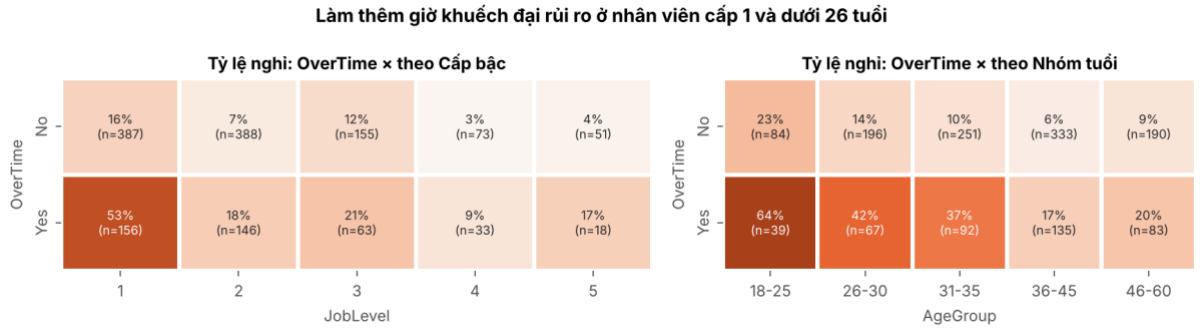


Hình 6: Tỷ lệ nghỉ việc theo sáu biến phân loại; cột cam là nhóm cao hơn trung bình 16,1%

Hình 6 giúp khoanh vùng nhanh trước khi kiểm định. Sáu nhóm nổi bật: làm thêm giờ (31%), công tác thường xuyên (25%), cấp bậc 1 (26%), độc thân (26%), Sales Representative (40%) và không có cổ phiếu (24%). Có hai điểm khó giải thích bằng mắt: tỷ lệ nghỉ theo cấp bậc *không đơn điệu* (cấp 3 cao hơn cấp 2), và StockOptionLevel 3 (18%) cao hơn mức 1–2. Cả hai được phân tích ở mục 5.4 và 5.7.

5.3 H1 — Làm thêm giờ: yếu tố mạnh nhất và kiểm soát được

Nhân viên làm thêm giờ nghỉ việc với tỷ lệ 30,5% so với 10,4% ở nhóm không làm thêm: rủi ro tương đối RR = 2,93; $\chi^2 = 87{,}6$; $p = 8{,}2\times10^{-21}$; Cramér's V = 0,246 — cao nhất trong các biến phân loại. Quan trọng hơn con số trung bình là tương tác (Hình 7).



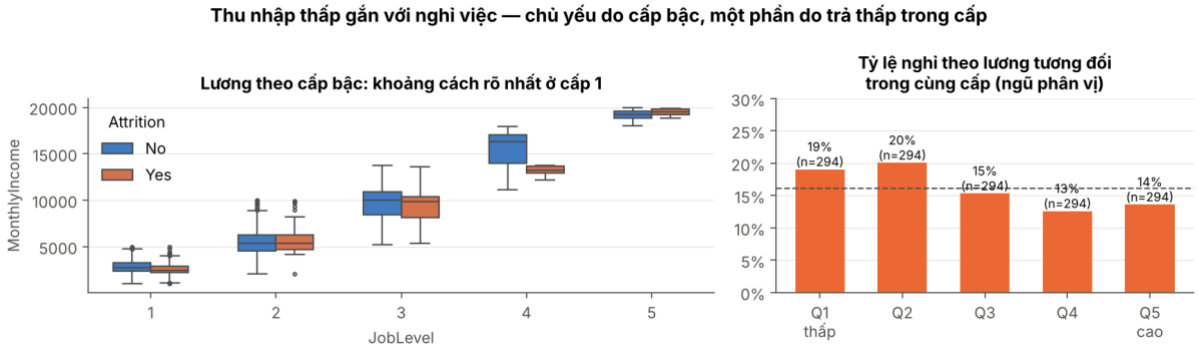
Hình 7: Tỷ lệ nghỉ theo OverTime kết hợp cấp bậc (trái) và nhóm tuổi (phải); mỗi ô ghi kèm cỡ mẫu

Ở nhân viên cấp 1 làm thêm giờ, tỷ lệ nghỉ là 53% (n = 156) — cứ hai người thì một người rời đi — trong khi cấp 1 không làm thêm chỉ 16%. Ở nhóm 18–25 tuổi làm thêm giờ, tỷ

lệ là 64% (n = 39). Ở cấp 4–5, làm thêm giờ chỉ làm tỷ lệ tăng nhẹ. Cách giải thích hợp lý: nhân viên cấp thấp làm thêm giờ mà không nhận thêm quyền hạn hay thu nhập tương xứng (lương cấp 1 trung vị chỉ 2.670) nên thấy "đổi" không đáng, trong khi nhân viên cấp cao xem làm thêm là một phần của vai trò. Bài học: chính sách làm thêm giờ không nên áp dụng như nhau cho mọi cấp — trần giờ làm thêm nên ưu tiên cấp 1 và nhân viên trẻ.

5.4 H2 — Thu nhập và công bằng nội bộ

Trung vị lương của người nghỉ là 3.202, của người ở lại là 5.204 ($p = 3{,}0\times10^{-14}$). Nhưng kết luận "lương thấp làm người ta nghỉ" là quá vội: vì lương tương quan 0,92 với cấp bậc, người nghỉ có lương thấp phần lớn *vì họ ở cấp thấp*. Để tách hai yếu tố, nhóm so sánh lương trong cùng cấp.



Hình 8: Lương theo cấp bậc và Attrition (trái); tỷ lệ nghỉ theo ngũ phân vị lương tương đối trong cùng cấp (phải)

Nhóm so sánh lương người nghỉ và người ở lại trong từng cấp. Vì thực hiện 5 kiểm định cùng lúc, p-value được hiệu chỉnh Bonferroni (nhân với 5); đồng thời nhóm đặt điều kiện tối thiểu 20 người nghỉ trong một cấp mới coi kết quả là đáng tin cậy (Bảng 10).

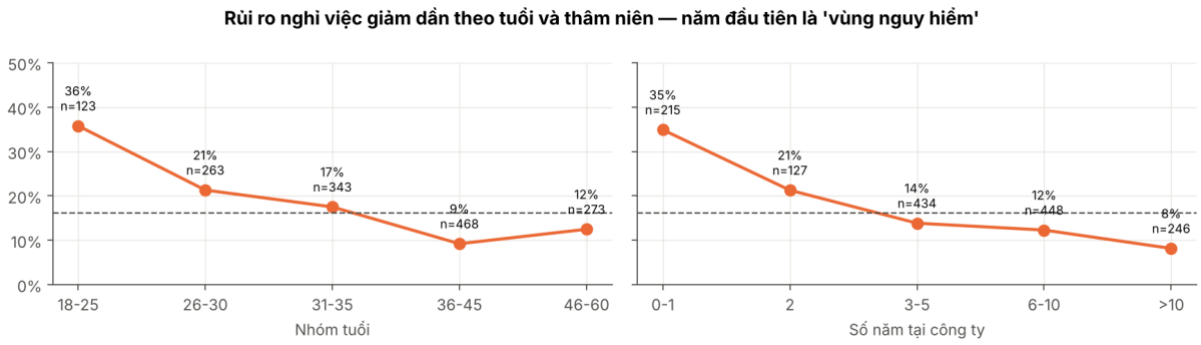
Cấp	n	n nghỉ	Median nghỉ	Median ở lại	p	p (Bonferroni)	Kết luận
1	543	143	2.437	2.719	0,0004	0,002	Có khác biệt
2	534	52	5.346	5.335	0,307	1,000	Không khác biệt
3	218	32	9.887	9.983	0,161	0,803	Không khác biệt
4	106	5	13.194	16.307	0,004	0,020	Có ý nghĩa nhưng chỉ 5 người nghỉ — không đủ tin cậy
5	69	5	19.545	19.200	0,206	1,000	Không khác biệt

Bảng 10: So sánh lương trong từng cấp bậc (Mann-Whitney U, hiệu chỉnh Bonferroni)

Sau khi kiểm soát cấp bậc, khác biệt lương chỉ vững ở cấp 1 (2.437 so với 2.719; p sau hiệu chỉnh = 0,002; 143 người nghỉ). Cấp 4 có p sau hiệu chỉnh = 0,020 nhưng chỉ dựa trên 5 người nghỉ, nên nhóm không đưa vào kết luận. Nhóm trả thấp nhất trong cấp (Q1–Q2) có tỷ lệ

nghỉ 19–20%, cao hơn nhóm Q4–Q5 (13–14%), nhưng chênh lệch theo ngũ phân vị chỉ là mô tả, và khi xét trên toàn bộ dữ liệu, RelPayInLevel không còn ý nghĩa sau hiệu chỉnh Bonferroni (Bảng 12). Kết luận: H2 được ủng hộ một phần. Phần lớn "hiệu ứng lương" thực chất là "hiệu ứng cấp bậc"; trả thấp so với đồng cấp chỉ là yếu tố phụ, và chỉ có bằng chứng ở cấp 1 — nơi nhân viên mới dễ so lương với thị trường. Tăng lương đại trà vì vậy không hiệu quả về chi phí.

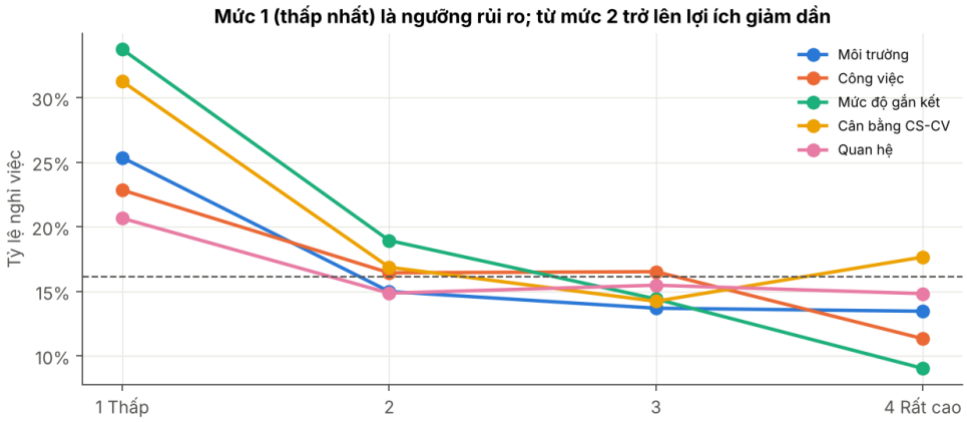
5.5 H3 — Giai đoạn sự nghiệp: tuổi và thâm niên



Hình 9: Tỷ lệ nghỉ theo nhóm tuổi và số năm tại công ty, kèm cỡ mẫu từng nhóm; đường đứt là tỷ lệ trung bình

Rủi ro giảm gần đơn điệu: từ 35,8% (18–25 tuổi) xuống 9,2% (36–45 tuổi), và từ 34,9% (0–1 năm tại công ty) xuống 8,1% (> 10 năm). Cả hai đều có ý nghĩa mạnh (Cramér's V = 0,20 và 0,23). Nhóm 0–1 năm chỉ chiếm 14,6% lực lượng nhưng tạo ra 31,6% tổng số người nghỉ, phù hợp với hiện tượng "sốc gia nhập": kỳ vọng khi tuyển dụng không khớp thực tế công việc. Tỷ lệ nhích lên ở nhóm 46–60 tuổi (12,5%) có thể do nghỉ hưu, nhưng dữ liệu không phân biệt loại nghỉ việc nên nhóm không kết luận thêm. Bài học: khoản đầu tư giữ chân hiệu quả nhất là 12 tháng đầu của nhân viên mới.

5.6 H4 — Mức độ hài lòng và gắn kết



Hình 10: Tỷ lệ nghỉ việc theo từng mức của năm thang khảo sát (1 = thấp nhất)

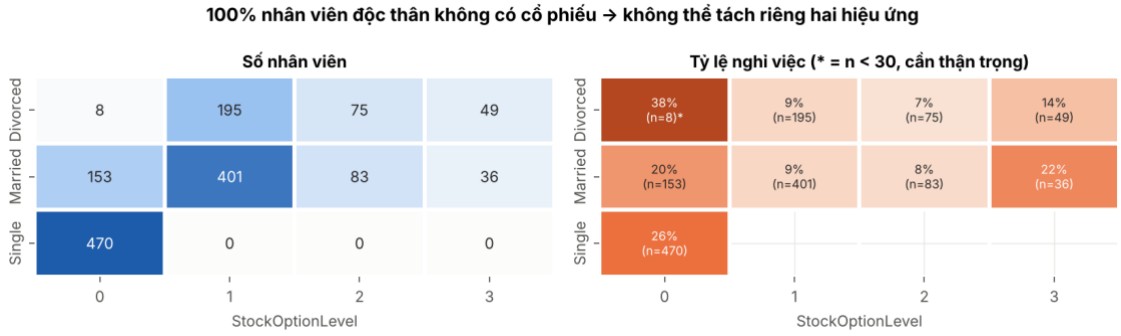
Thang đo	**Nghỉ @ mức 1**	**Nghỉ @ mức 4**	**χ^2 p (4 mức)**	**Cramér's V**	**Mức 1 vs 2–4: p**
Mức độ gắn kết	33,7%	9,0%	$2{,}9\times10^{-6}$	0,139	< 0,001
Cân bằng CV – CS	31,2%	17,6%	$9{,}7\times10^{-4}$	0,105	< 0,001
Hài lòng môi trường	25,4%	13,5%	$5{,}1\times10^{-5}$	0,124	< 0,001
Hài lòng công việc	22,8%	11,3%	$5{,}6\times10^{-4}$	0,109	< 0,001
Hài lòng quan hệ	20,7%	14,8%	0,155	0,060	0,029

Bảng 11: Tỷ lệ nghỉ ở hai đầu thang khảo sát; kiểm định χ^2 trên cả 4 mức và χ^2 2×2 so sánh mức 1 với các mức còn lại

Ngoài kiểm định χ^2 trên cả 4 mức, nhóm so sánh riêng mức 1 với mức 2–4 bằng một kiểm định χ^2 2×2. Cả năm thang đều có mức 1 khác các mức còn lại ($p \leq 0{,}029$). Đáng chú ý, thang quan hệ không có ý nghĩa khi xét cả 4 mức ($p = 0{,}155$) nhưng mức 1 vẫn khác phần còn lại — dấu hiệu của hiệu ứng ngưỡng.

Có hai phát hiện dễ bị bỏ qua nếu chỉ nhìn tương quan. (1) Hiệu ứng ngưỡng: khoảng cách lớn nhất nằm giữa mức 1 và mức 2; từ mức 2 trở lên đường cong gần phẳng. Hài lòng thấp là *tín hiệu cảnh báo*, còn nâng hài lòng từ "khá" lên "rất cao" ít tác dụng — đúng với thuyết hai nhân tố của Herzberg. (2) Cân bằng công việc – cuộc sống không đơn điệu: mức 4 có tỷ lệ nghỉ 17,6%, cao hơn mức 3; có thể nhóm này đang ít được giao việc, ít gắn kết. Bài học: HR nên theo dõi *tỷ lệ nhân viên chấm mức 1*, nhất là ở thang gắn kết, thay vì theo dõi điểm trung bình.

5.7 H5 — Cổ phiếu và tình trạng hôn nhân: một biến gây nhiễu cấu trúc

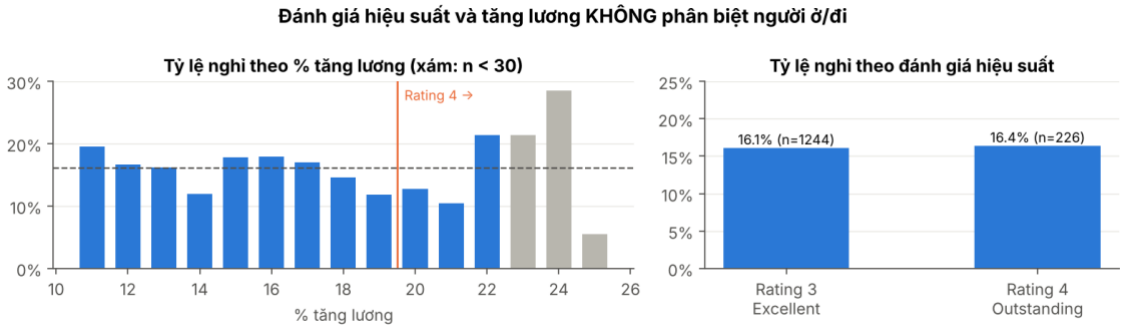


*Hình 11: Bảng chéo MaritalStatus × StockOptionLevel: số nhân viên (trái) và tỷ lệ nghỉ kèm cỡ mẫu (phải); * = ô có n < 30*

Toàn bộ 470 nhân viên độc thân đều có StockOptionLevel = 0. Hai biến bị trộn lẫn hoàn toàn, nên không thể biết tỷ lệ nghỉ 25,5% của nhóm độc thân là do hôn nhân hay do không có cổ phiếu. Nhóm phân tầng: chỉ xét nhóm đã/đã từng kết hôn, tỷ lệ nghỉ khi không có cổ phiếu là 21,1% (n = 161) so với 9,9% khi có (n = 839), $p = 8{,}7\times10^{-5}$. Như vậy cổ phiếu vẫn giữ chân nhân viên sau khi kiểm soát hôn nhân. Tỷ lệ cao ở mức 3 (17,6%, n = 85) có mẫu nhỏ, chưa đủ cơ sở kết luận; tương tự, ô Divorced/Stock 0 có tỷ lệ 38% nhưng chỉ n = 8 nên không được diễn giải. Bài học kép: (a) việc cấp cổ phiếu dường như phụ thuộc vào hôn nhân — có thể vi phạm nguyên tắc không phân biệt đối xử và cần rà soát; (b) nếu chỉ nhìn tương quan đơn biến, "độc thân" sẽ bị kết luận nhầm là nguyên nhân.

5.8 H6 và H7 — Vị trí, công tác và hiệu suất

H6 được ủng hộ. `JobRole` có Cramér's V = 0,242, gần bằng OverTime. Sales Representative (39,8%), Laboratory Technician (23,9%) và Human Resources (23,1%) rủi ro cao; Research Director (2,5%) và Manager (4,9%) thấp nhất. Công tác thường xuyên làm tỷ lệ nghỉ lên 24,9% so với 8,0% ở nhóm không đi công tác. Ngược lại, `Department` chỉ có V = 0,086: rủi ro nằm ở *vị trí*, không ở *phòng ban*.



Hình 12: Tỷ lệ nghỉ theo % tăng lương (trái) và theo mức đánh giá hiệu suất (phải)

H7 không được ủng hộ — và đây là một phát hiện có giá trị. PerformanceRating chỉ có hai mức 3 và 4 trên thang 1–4, và tỷ lệ nghỉ gần như bằng nhau (16,1% so với 16,4%; p = 0,99), nên không bác bỏ được giả thuyết "không có khác biệt". % tăng lương do mức đánh giá quyết định (11–19% cho mức 3; 20–25% cho mức 4) và cũng không phân biệt người ở/đi. Hai hệ quả: (a) lạm phát đánh giá — hệ thống không phân biệt được hiệu suất; (b) tăng lương theo hiệu suất không phải công cụ giữ chân trong tổ chức này.

5.9 Tổng hợp kiểm định với hiệu chỉnh đa kiểm định

Nhóm thực hiện 28 kiểm định. Với $\alpha = 0,05$, kỳ vọng có 1–2 kết quả dương tính giả chỉ do ngẫu nhiên, nên p-value được hiệu chỉnh Bonferroni: một biến chỉ được coi là có ý nghĩa khi $p < 0,05/28 \approx 0,0018$ (tương đương nhân p với 28). Đây là cách hiệu chỉnh thận trọng. Kết quả: 16/28 biến vẫn có ý nghĩa.

Biến	Kiểm định	Độ mạnh / trung vị (nghỉ vs ở lại)	p (Bonferroni)	Kết luận
OverTime	χ^2	V = 0,25	$2{,}3\times10^{-19}$	Có liên hệ
JobRole	χ^2	V = 0,24	$7{,}7\times10^{-14}$	Có liên hệ
JobLevel	χ^2	V = 0,22	$1{,}9\times10^{-13}$	Có liên hệ
TotalWorkingYears	Mann-Whitney	7 vs 10 năm	$6{,}7\times10^{-13}$	Có liên hệ
MonthlyIncome	Mann-Whitney	3.202 vs 5.204	$8{,}3\times10^{-13}$	Có liên hệ
YearsAtCompany	Mann-Whitney	3 vs 6 năm	$8{,}2\times10^{-12}$	Có liên hệ
StockOptionLevel	χ^2	V = 0,20	$1{,}2\times10^{-11}$	Có liên hệ
YearsInCurrentRole; YearsWithCurrManager	Mann-Whitney	2 vs 3 năm	$< 10^{-9}$	Có liên hệ
Age	Mann-Whitney	32 vs 36 tuổi	$1{,}5\times10^{-9}$	Có liên hệ
MaritalStatus	χ^2	V = 0,18	$2{,}6\times10^{-9}$	Có liên hệ (bị nhiễu)
JobInvolvement; BusinessTravel	χ^2	V = 0,14; 0,13	< 0,001	Có liên hệ
EnvironmentSatisfaction; JobSatisfaction; WorkLifeBalance	χ^2	V = 0,11 – 0,12	0,001 – 0,027	Có liên hệ
DistanceFromHome	Mann-Whitney	9 vs 7 km	0,067	Không đủ bằng chứng
Department; EducationField	χ^2	V = 0,09; 0,10	0,13; 0,19	Không đủ bằng chứng
RelPayInLevel	Mann-Whitney	0,96 vs 1,01	0,23	Không đủ bằng chứng
YearsSinceLastPromotion	Mann-Whitney	1 vs 1 năm	1,00	Không đủ bằng chứng*
RelationshipSatisfaction, Gender, Education, NumCompaniesWorked, PercentSalaryHike, PerformanceRating, TrainingTimesLastYear	χ^2 / MWU	—	1,00	Không có liên hệ

Bảng 12: Tổng hợp kiểm định, sắp xếp theo p-value (rút gọn; bảng đầy đủ 28 dòng trong notebook mục 3.9)

** YearsSinceLastPromotion không có ý nghĩa khi xét riêng lẻ (p chưa hiệu chỉnh = 0,041), nhưng có ý nghĩa trong mô hình đa biến rút gọn (OR = 1,74; mục 6.4).*

Giới tính (p = 0,29) và học vấn (p = 0,55) không liên quan đến nghỉ việc. Đây là thông tin tích cực: rủi ro đến từ *điều kiện làm việc* — những yếu tố doanh nghiệp thay đổi được — chứ không đến từ đặc điểm cá nhân.

5.10 Kết luận EDA

Từ các phân tích trên:

- Nghỉ việc có liên hệ với 16/28 biến sau hiệu chỉnh Bonferroni, nhưng không biến nào vượt |0,25| — cần mô hình đa biến để kết hợp các tín hiệu yếu.
- Một số hiệu ứng chỉ xuất hiện khi xét tương tác (OverTime × cấp bậc) hoặc khi kiểm soát biến khác (lương trong cùng cấp; cổ phiếu trong nhóm đã kết hôn).
- Quan hệ chủ yếu là đơn điệu hoặc có ngưỡng — phù hợp với mô hình tuyến tính sau log hóa.
- Có cụm đa cộng tuyến thâm niên – cấp bậc – thu nhập — cần đo VIF và dùng mô hình rút gọn khi diễn giải hệ số.
- Kết luận: việc xây dựng mô hình dự báo là cần thiết và khả thi. Nhóm chuyển sang Chương 6.

6 Mô hình dự báo rủi ro nghỉ việc (Giai đoạn 3)

6.1 Lựa chọn thuật toán

Logistic Regression mô hình hóa log-odds của nghỉ việc là tổ hợp tuyến tính của các biến. Ưu điểm chính là khả năng diễn giải: exp(hệ số) là *odds ratio*, cho biết odds nghỉ việc thay đổi bao nhiêu lần khi biến liên tục tăng một độ lệch chuẩn, hoặc khi biến 0/1 chuyển từ 0 sang 1. Phạt L2 giúp ổn định hệ số khi có đa cộng tuyến; mức phạt C được chọn trong {0,01; 0,03; 0,1; 0,3; 1; 3}.

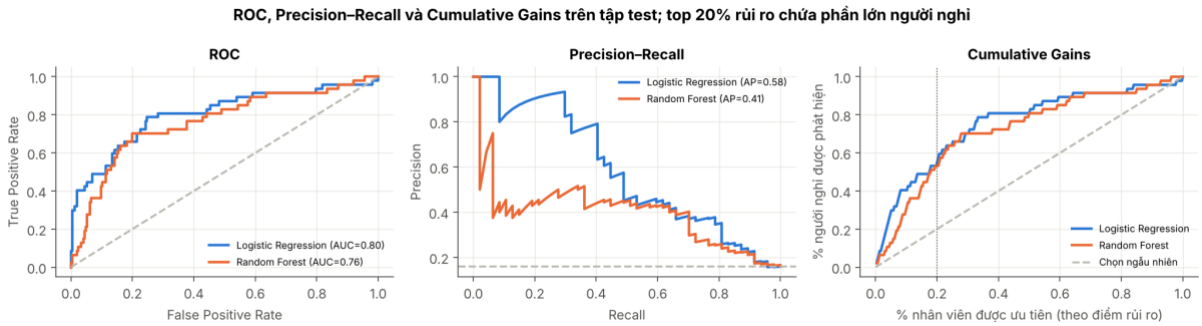
Random Forest kết hợp 400 cây quyết định huấn luyện trên các mẫu bootstrap và tập con biến ngẫu nhiên. Mô hình bắt được tương tác phi tuyến mà không cần khai báo trước, và không cần chuẩn hóa. Tham số được chọn trong min_samples_leaf ∈ {1; 3; 5; 10} và max_features ∈ {sqrt; 0,3}.

Thiết kế đánh giá: chia train/test 80/20 có phân tầng (16,2% / 16,0% nghỉ việc). Cả hai mô hình được tinh chỉnh bằng GridSearchCV (CV 5-fold, chỉ trên tập train) để so sánh công bằng; tập test chỉ dùng một lần ở cuối. Mọi tiền xử lý nằm trong Pipeline; class_weight = 'balanced'. Thước đo chính là ROC-AUC và PR-AUC, kèm Recall cho lớp "Nghỉ việc". Vì tập test chỉ có 47 người nghỉ, kết quả trên tập test có thể dao động; nhóm vì vậy báo cáo cả AUC kiểm định chéo (cv = 5) và AUC trên tập test.

6.2 Hiệu năng mô hình

Mô hình	Tham số chọn	CV ROC-AUC	Test ROC-AUC	PR-AUC	Recall	Precision	F1
Logistic Regression	C = 0,03	0,849 ± 0,030	0,803	0,584	0,660	0,392	0,492
Random Forest	leaf = 3; max_feat = 0,3	0,819 ± 0,022	0,762	0,405	0,170	0,421	0,242
Logistic (bỏ Gender, Age, MaritalStatus)	C = 0,03	0,846	0,794	0,573	0,702	0,402	0,512
Baseline: luôn đoán "No"	—	0,500	0,500	0,160	0	0	0

Bảng 13: So sánh mô hình đã tinh chỉnh (Recall/Precision/F1 ở ngưỡng 0,5 cho lớp "Nghỉ việc")



Hình 13: Đường ROC, Precision–Recall và Cumulative Gains trên tập kiểm tra (294 nhân viên)

So sánh hai mô hình. Logistic Regression cao hơn Random Forest ở cả AUC kiểm định chéo (0,849 so với 0,819), AUC trên tập test (0,803 so với 0,762) và PR-AUC (0,584 so với 0,405). Tuy nhiên, tập test chỉ có 47 người nghỉ, nên chênh lệch 0,04 AUC chưa đủ để khẳng định Logistic vượt trội một cách chắc chắn. Nhóm chọn Logistic làm mô hình chính vì kết quả nhất quán trên cả hai cách đánh giá và hệ số diễn giải được. Hai đặc điểm của dữ liệu giải thích vì sao mô hình đơn giản không thua: dữ liệu nhỏ (1.176 dòng huấn luyện, 190 ca nghỉ việc) và quan hệ chủ yếu đơn điệu hoặc có ngưỡng (Hình 9, 10). Random Forest ở ngưỡng 0,5 chỉ phát hiện 17% người nghỉ. Mốc "luôn đoán No" (AUC 0,5; PR-AUC 0,16) xác nhận cả hai mô hình đều học được cấu trúc thật.

Giá trị kinh doanh. Nếu HR chỉ tập trung vào 20% nhân viên có điểm rủi ro cao nhất trong tập test, nhóm này chứa 53% số người thực sự nghỉ (tỷ lệ nghỉ trong nhóm 43%) — hiệu quả gấp 2,7 lần so với chọn ngẫu nhiên. Với mô hình không dùng thuộc tính nhạy cảm — mô hình nhóm đề xuất triển khai (mục 6.5 và 7.5) — top 20% chứa 55% số người nghỉ (lift 2,8x; tỷ lệ nghỉ trong nhóm 45%).

6.3 Ngưỡng phân loại và ma trận nhầm lẫn

Nhóm dùng ngưỡng mặc định 0,5 cho mô hình Logistic không dùng thuộc tính nhạy cảm. Ma trận nhầm lẫn trên tập test:

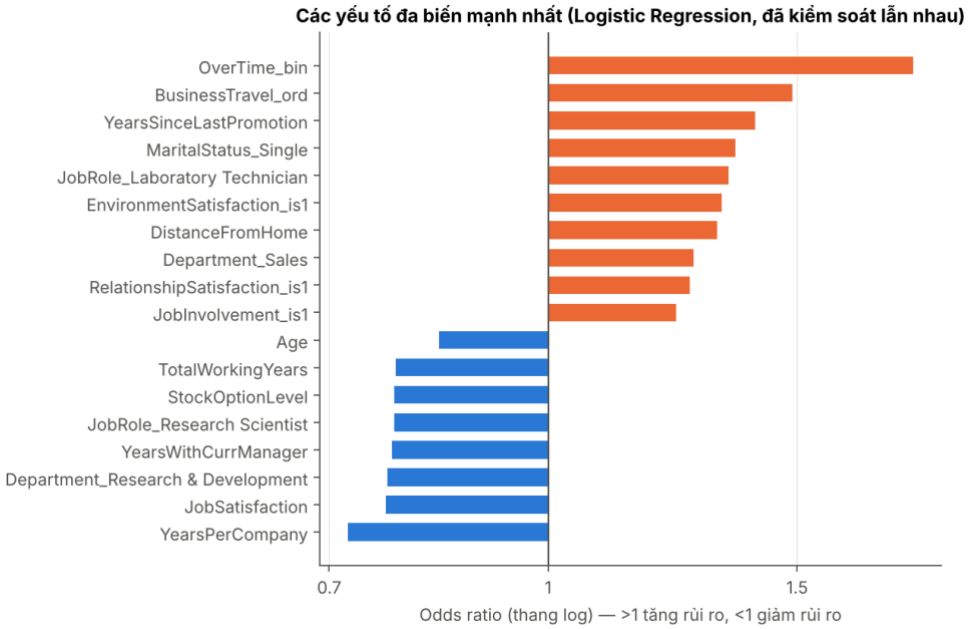
	Dự báo: Ở lại	**Dự báo: Nghỉ**	**Tổng**
Thực tế: Ở lại	198 (TN)	49 (FP)	247
Thực tế: Nghỉ	14 (FN)	33 (TP)	47

Bảng 14: Ma trận nhầm lẫn trên tập test ở ngưỡng 0,5 (Logistic, không dùng thuộc tính nhạy cảm)

Mô hình phát hiện 33/47 người nghỉ (recall 70%; precision 40%), bỏ sót 14 và báo động nhầm 49/247 người ở lại. Đây là đánh đổi giữa recall và precision: hạ ngưỡng sẽ phát hiện thêm người nghỉ nhưng báo động nhầm nhiều hơn, và ngược lại. Trong bối cảnh nhân sự, bỏ sót một người sắp nghỉ thường tốn kém hơn một buổi trao đổi thừa, nên recall được ưu tiên.

Nhờ class_weight = 'balanced', ngưỡng 0,5 đã cho recall 70%, chấp nhận được cho mục đích sàng lọc.

6.4 Diễn giải mô hình



Hình 14: Odds ratio của Logistic Regression: cho mỗi +1 độ lệch chuẩn (biến số) hoặc so với nhóm tham chiếu (biến one-hot)

Hình 14 cho thấy hệ số của mô hình dự báo. Do phạt L2 mạnh (C = 0,03), các hệ số bị co về phía 1 và không có p-value, nên chỉ dùng để xếp hạng, không dùng để kết luận. Để kết luận, nhóm làm hai bước kiểm chứng theo cách của Kinh tế lượng:

- Đo đa cộng tuyến bằng VIF. Mô hình đầy đủ có VIF rất cao: YearsPerCompany 87,9; TotalWorkingYears 70,2; NumCompaniesWorked 48,7; MonthlyIncome 41,2; JobLevel 36,9. Nguyên nhân là các đặc trưng phái sinh (YearsPerCompany, PromotionStagnation, RelPayInLevel) được tính từ chính các biến gốc. Trong mô hình này, OR của JobLevel là 11,5 với KTC 1,6–82 — một con số vô nghĩa do đa cộng tuyến. Các đặc trưng phái sinh vẫn được giữ trong mô hình dự báo vì chúng mang thông tin hữu ích (YearsPerCompany đứng đầu Hình 15) và đa cộng tuyến không làm giảm độ chính xác dự báo; nhóm chỉ bỏ chúng khi cần diễn giải từng hệ số.
- Ước lượng lại bằng Logit không phạt (statsmodels) trên mô hình rút gọn, đã bỏ 3 đặc trưng phái sinh và TotalWorkingYears. VIF lớn nhất giảm còn 7,1, và mỗi hệ số có KTC 95% cùng p-value (Bảng 15).

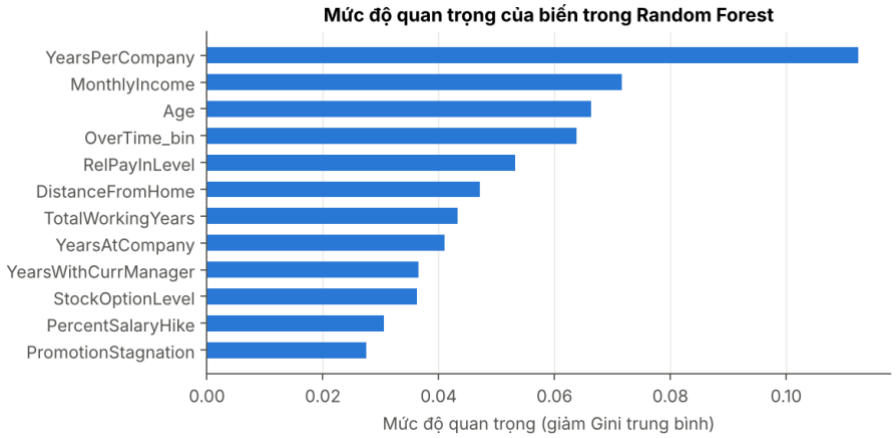
Biến	OR	KTC 95%	p	Diễn giải
OverTime (có so với không)	7,69	5,22 – 11,32	< 0,001	Yếu tố mạnh nhất
JobRole: Laboratory Technician	3,15	1,17 – 8,47	0,023	Có ý nghĩa, KTC rất rộng
WorkLifeBalance = 1	3,01	1,24 – 7,30	0,015	Hiệu ứng ngưỡng
EnvironmentSatisfaction = 1	2,49	1,25 – 4,96	0,010	Hiệu ứng ngưỡng
YearsSinceLastPromotion	1,74	1,37 – 2,23	< 0,001	Hiệu ứng ẩn
BusinessTravel	1,65	1,37 – 1,99	< 0,001	Tăng rủi ro
NumCompaniesWorked	1,58	1,23 – 2,04	< 0,001	Tiền sử nhảy việc
DistanceFromHome	1,52	1,26 – 1,83	< 0,001	Tăng rủi ro
MonthlyIncome	0,48	0,30 – 0,78	0,003	Giảm rủi ro
YearsWithCurrManager	0,60	0,44 – 0,83	0,002	Giảm rủi ro
YearsInCurrentRole	0,65	0,47 – 0,90	0,010	Giảm rủi ro
JobSatisfaction	0,67	0,50 – 0,89	0,006	Giảm rủi ro
JobInvolvement	0,74	0,59 – 0,93	0,010	Giảm rủi ro
JobLevel	1,36	0,79 – 2,33	0,266	*Không có ý nghĩa*
StockOptionLevel	0,89	0,69 – 1,15	0,380	*Không có ý nghĩa**
JobRole: Sales Representative	10,2	0,98 – 107	0,052	*Không có ý nghĩa ở mức 5%*

Bảng 15: Odds ratio từ Logit không phạt, mô hình rút gọn (VIF ≤ 7,1); toàn bộ 1.470 nhân viên

*OR của biến liên tục tính cho mỗi +1 độ lệch chuẩn; OR của biến 0/1 (OverTime, các cờ "= 1") và one-hot (JobRole) là có so với không, hoặc so với nhóm tham chiếu. OR = 7,69 của OverTime lớn hơn RR = 2,93 ở mục 5.3 vì hai lý do: OR luôn lớn hơn RR khi kết cục không hiếm (16%), và OR ở đây đã kiểm soát các biến khác. * StockOptionLevel mất ý nghĩa vì mô hình đã chứa MaritalStatus, mà hai biến trùng thông tin gần như hoàn toàn (mục 5.7).*

Kết quả kiểm chứng làm rõ thêm bốn điểm so với chỉ đọc hệ số có phạt:

- YearsSinceLastPromotion có ý nghĩa (OR = 1,74; KTC 1,37–2,23). Xét riêng lẻ, biến này không có ý nghĩa (Bảng 12). Khi giữ nguyên thời gian ở vị trí hiện tại và với quản lý hiện tại, *càng lâu chưa được thăng chức thì rủi ro càng cao*. Hiệu ứng bị che vì người lâu chưa thăng chức thường có thâm niên dài, vốn ít nghỉ.
- JobLevel không còn ý nghĩa khi đã kiểm soát thu nhập (KTC 0,79–2,33 chứa 1). Nhận định "cùng lương, cấp cao hơn lại rủi ro hơn" *không* được dữ liệu ủng hộ.
- Laboratory Technician vẫn có ý nghĩa nhưng ước lượng kém chính xác (KTC 1,17–8,47); Sales Representative không có ý nghĩa ở mức 5% (p = 0,052; KTC 0,98–107). Khoảng tin cậy rộng vì mỗi vị trí chỉ có vài chục người, nên nhóm không xây khuyến nghị riêng cho từng vị trí.
- Một phát hiện mới: NumCompaniesWorked (OR = 1,58) — người từng đổi nhiều công ty có rủi ro cao hơn khi các yếu tố khác như nhau.



Hình 15: Mức độ quan trọng của biến trong Random Forest (feature_importances_, mức giảm Gini trung bình)

Theo Random Forest (Hình 15), các biến quan trọng nhất là YearsPerCompany, MonthlyIncome, Age và OverTime — nhất quán với Logistic ở chỗ thu nhập, tuổi/thâm niên và làm thêm giờ đều nằm trong nhóm đầu. Lưu ý: chỉ số này đo theo mức giảm Gini, nên thường đánh giá cao các biến liên tục có nhiều giá trị và đánh giá thấp biến nhị phân như OverTime. Vì vậy nhóm chỉ dùng Hình 15 để tham khảo, còn kết luận dựa trên Bảng 15.

6.5 Kiểm tra khi bỏ thuộc tính nhạy cảm

Khi bỏ ba thuộc tính nhạy cảm (giới tính, tuổi, hôn nhân), AUC kiểm định chéo gần như không đổi (0,849 → 0,846) và AUC tập test giảm 0,009. Như vậy doanh nghiệp có thể dự báo rủi ro mà không cần dùng các thuộc tính này. Tuy nhiên, bỏ thuộc tính nhạy cảm *không bảo đảm* mô hình công bằng, vì thâm niên, cấp bậc và số năm làm việc là biến đại diện gián tiếp cho tuổi. Nhóm chưa đánh giá hiệu năng riêng cho từng nhóm giới tính và tuổi, và nêu đây là giới hạn (mục 8.2). Do đó mô hình chỉ nên dùng như *công cụ hỗ trợ* để ưu tiên trao đổi, có quản lý rà soát, không dùng để ra quyết định nhân sự.

7 Đánh giá tác động và khuyến nghị (Giai đoạn 4)

7.1 Trả lời câu hỏi nghiên cứu

Q1 — Nguyên nhân: làm thêm giờ, giai đoạn đầu sự nghiệp, cấp bậc thấp, thiếu cổ phiếu, lâu chưa thăng chức và mức gắn kết thấp là các yếu tố chính. Giới tính, học vấn và đánh giá hiệu suất không liên quan. Q2 — Dự báo: có, nhưng có điều kiện. Logistic không dùng thuộc tính nhạy cảm đạt AUC 0,79 trên tập test (0,85 khi kiểm định chéo) và nhóm top 20% chứa 55% số người nghỉ; vì chưa đánh giá công bằng theo nhóm, mô hình chỉ nên dùng như công cụ hỗ trợ. Q3 — Tác động: xem mục 7.4.

7.2 Quy mô tác động tài chính

Gallup ước tính chi phí thay thế một nhân viên bằng 0,5–2 lần lương năm. Dữ liệu không ghi đơn vị tiền tệ, nên kết quả trình bày theo đơn vị tiền tệ của dữ liệu.

Kịch bản	**Hệ số 0,5x (thận trọng)**	**Hệ số 1,0x (trung bình)**	**Hệ số 2,0x (cao)**
Tổng chi phí thay thế 237 người	6.807.246	13.614.492	27.228.984

Bảng 16: Ước tính chi phí do nghỉ việc

7.3 Phân khúc ưu tiên

Phân khúc	**Số người**	**% lực lượng**	**Tỷ lệ nghỉ**	**% tổng người nghỉ**	**Lift**
OverTime + JobLevel 1 + không cổ phiếu	75	5,1%	66,7%	21,1%	4,1x
OverTime + tuổi ≤ 25	39	2,7%	64,1%	10,5%	4,0x
OverTime + JobLevel 1	156	10,6%	52,6%	34,6%	3,3x
Sales Representative	83	5,6%	39,8%	13,9%	2,5x
Năm đầu tiên (YearsAtCompany ≤ 1)	215	14,6%	34,9%	31,6%	2,2x

Bảng 17: Các phân khúc rủi ro cao (lift = tỷ lệ nghỉ / tỷ lệ trung bình; các phân khúc có thể giao nhau)

Nhóm "làm thêm giờ + cấp 1" là trọng tâm: chỉ chiếm 10,6% lực lượng nhưng chiếm 34,6% số người nghỉ, vừa rủi ro cao vừa có đòn bẩy kiểm soát rõ ràng.

7.4 Điểm hòa vốn của chương trình giữ chân

Nhóm tính điểm hòa vốn cho phân khúc trọng tâm "làm thêm giờ + cấp 1" (156 người, 82 người nghỉ). Giả định chương trình can thiệp tốn 1 tháng lương cho *mỗi* nhân viên trong

phân khúc, tổng cộng 437.197. Chi phí nghỉ việc của phân khúc bằng tổng lương năm của 82 người nghỉ nhân với hệ số thay thế. Điểm hòa vốn là tỷ lệ người nghỉ cần giữ lại để khoản tiết kiệm bằng chi phí chương trình:

Tỷ lệ cần giữ lại = Chi phí chương trình / Chi phí nghỉ việc của phân khúc

Hệ số thay thế	**Chi phí nghỉ việc của phân khúc**	**Tỷ lệ cần giữ lại để hòa vốn**	**Số người cần giữ lại (trên 82)**
0,5x lương năm (thận trọng)	1.286.646	34%	≈ 28
1,0x lương năm (trung bình)	2.573.292	17%	≈ 14
2,0x lương năm (cao)	5.146.584	8,5%	≈ 7

Bảng 18: Điểm hòa vốn của chương trình giữ chân cho phân khúc "OverTime + cấp 1"

Mức này có khả thi không? Theo Gallup, 52% người nghỉ tự nguyện cho rằng quản lý hoặc tổ chức đã có thể giữ họ lại — đây là *trần trên*. Các meta-analysis về can thiệp giữ chân cho thấy hiệu quả thường ở mức nhỏ đến vừa: mô tả công việc thực tế (realistic job preview) chỉ cải thiện tỷ lệ giữ chân ở mức nhỏ (Phillips, 1998; Earnest, Allen & Landis, 2011), còn làm giàu công việc (job enrichment) hiệu quả khoảng gấp đôi (McEvoy & Cascio, 1985). Một mô phỏng can thiệp nhắm mục tiêu giảm được khoảng 42% số người nghỉ (Ribes và cộng sự, 2017) — đây là kịch bản lạc quan. Như vậy mức 17% (kịch bản trung bình) là khả thi, còn mức 34% (kịch bản thận trọng) là khó. Chi phí can thiệp 1 tháng lương là *giả định của nhóm*, chưa có nguồn đối chiếu.

Đánh giá phản biện. Chương trình giữ chân không phải lúc nào cũng có lãi. Với giả định thận trọng nhất (hệ số thay thế 0,5x), phải giữ lại 34% số người sẽ nghỉ mới hòa vốn — một mục tiêu khó. Hai kết luận thực tế: (1) ưu tiên can thiệp chi phí thấp (quản lý giờ làm thêm, onboarding, lộ trình thăng tiến) thay vì thưởng tiền mặt; (2) mọi chương trình nên thí điểm có nhóm đối chứng (A/B test) để đo hiệu quả thật trước khi mở rộng.

7.5 Chiến lược theo phân khúc

Mỗi khuyến nghị đi kèm KPI có mức hiện tại, mục tiêu và thời hạn. Với các KPI về tỷ lệ nghỉ việc, mục tiêu được neo ở mức giảm 17% — điểm hòa vốn của kịch bản trung bình (hệ số thay thế 1x, Bảng 18). Đạt mục tiêu này nghĩa là chương trình ít nhất tự bù được chi phí.

#	**Hành động**	**Nhóm mục tiêu**	**Căn cứ**	**KPI: hiện tại → mục tiêu (thời hạn)**
1	Đặt trần giờ làm thêm và luân phiên ca cho cấp 1; nếu bắt buộc thì trả bù bằng tiền hoặc ngày nghỉ	OverTime + cấp 1 (156 người)	53% nghỉ; OR = 7,7 [5,2; 11,3]; quan trọng nhất ở cả hai mô hình	Tỷ lệ nghỉ của nhóm: 52,6% → ≤ 43,7% (12 tháng). Tỷ lệ cấp 1 làm thêm giờ: 28,7% → ≤ 20% (6 tháng)
2	Chương trình 12 tháng đầu: người hướng dẫn, gặp mặt 30/90/180 ngày, rà soát kỳ vọng	Nhân viên mới, ≤ 25 tuổi	0–1 năm: 34,9%; chiếm 31,6% người nghỉ	Tỷ lệ nghỉ trong năm đầu: 34,9% → ≤ 29,0% (lứa tuyển dụng 12 tháng tới)
3	Rà soát công bằng lương ở cấp 1; công bố khung lương	Cấp 1 thuộc Q1–Q2 RelPayInLevel	Khác biệt lương vững duy nhất ở cấp 1 (p sau hiệu chỉnh = 0,002); cấp 1 lương < 90% trung vị nghỉ 34,6% so với 22,1%	Tỷ lệ cấp 1 có lương < 90% trung vị cấp: 34,1% → ≤ 20% (12 tháng)
4	Mở rộng cổ phiếu/thưởng dài hạn, tách khỏi tình trạng hôn nhân	631 người không có cổ phiếu	Đã kiểm soát hôn nhân: 21,1% → 9,9%	Bao phủ thưởng dài hạn: 57,1% → ≥ 70% (12 tháng). Tỷ lệ nghỉ nhóm chưa có cổ phiếu (đã kết hôn): 21,1% → ≤ 17,5%
5	Lộ trình thăng tiến minh bạch; xem xét định kỳ khi quá 3 năm chưa thăng chức	Nhân viên lâu chưa thăng chức	OR = 1,74 [1,37; 2,23] trong mô hình rút gọn (hiệu ứng ẩn)	% nhân viên ≥ 3 năm chưa thăng chức: 25,4% → ≤ 20% (18 tháng); 100% trường hợp được xét duyệt
6	Cải tổ đánh giá hiệu suất: dùng đủ thang 1–4, có hướng dẫn phân phối	Toàn công ty	Chỉ 2 mức được dùng; p = 0,99	Số mức đánh giá thực sự được dùng: 2 → ≥ 3 (kỳ đánh giá kế tiếp)
7	Cảnh báo sớm hằng quý bằng mô hình không dùng thuộc tính nhạy cảm, *có quản lý rà soát*; trao đổi ngay khi nhân viên chấm mức 1 ở thang khảo sát	Top 20% điểm rủi ro	Top 20% chứa 55% người nghỉ trên tập test; recall 70% ở ngưỡng 0,5	Recall ≥ 60% (mỗi quý). Tỷ lệ nghỉ nhóm được can thiệp thấp hơn nhóm đối chứng ≥ 17% (12 tháng)

Bảng 19: Tổng hợp chiến lược và KPI, xếp theo mức ưu tiên

8 Kết luận

8.1 Tóm tắt

Nghỉ việc trong dữ liệu IBM không do một nguyên nhân duy nhất mà là kết quả của nhiều yếu tố yếu cộng dồn — tương quan đơn biến không vượt 0,25. Khi phân tích tương tác và đa biến, một bức tranh rõ ràng xuất hiện: nhân viên trẻ, cấp thấp, mới vào công ty, phải làm thêm giờ và không có quyền lợi dài hạn là nhóm rủi ro cốt lõi; mô hình đa biến bổ sung thêm yếu tố lâu chưa được thăng chức và tiền sử nhảy việc. Phần lớn các yếu tố này doanh nghiệp kiểm soát được, trong khi giới tính và học vấn không liên quan. Logistic Regression (AUC 0,80 trên tập test; 0,79 khi bỏ thuộc tính nhạy cảm) cho phép tập trung vào 20% nhân viên mà vẫn bao phủ hơn một nửa số người sẽ nghỉ (53–55%), nhưng chưa được đánh giá công bằng theo từng nhóm nên chỉ phù hợp làm công cụ hỗ trợ. Về phương pháp, bài làm cho thấy giá trị của việc phân tầng để xử lý biến gây nhiễu, hiệu chỉnh đa kiểm định, kiểm chứng hệ số bằng VIF và khoảng tin cậy, và đánh giá kết quả bằng thước đo kinh doanh (lift, chi phí, điểm hòa vốn).

8.2 Giới hạn

- Dữ liệu giả lập. Các bất thường (ba cột Rate ngẫu nhiên, lỗi NumCompaniesWorked, 100% độc thân không có cổ phiếu) là dấu hiệu của bộ sinh dữ liệu. Kết luận nên xem là khung phương pháp, cần kiểm chứng trên dữ liệu thật.
- Dữ liệu cắt ngang. Không có ngày nghỉ việc nên không xây được mô hình thời gian sống; không biết khảo sát hài lòng được đo trước hay sau quyết định nghỉ (rủi ro nhân quả ngược).
- Tương quan, không phải nhân quả. Làm thêm giờ có thể là hệ quả của nhóm thiếu người do đồng nghiệp đã nghỉ. Cần thử nghiệm có đối chứng để khẳng định nhân quả.
- Không phân biệt loại nghỉ việc (tự nguyện, bị cho thôi việc, nghỉ hưu).
- Cỡ mẫu nhỏ ở một số ô (Stock 3: n = 85; OverTime × 18–25 tuổi: n = 39; cấp 4–5 chỉ 5 người nghỉ mỗi cấp) và tập test chỉ có 47 người nghỉ, nên kết quả trên tập test có thể dao động.
- Chưa đánh giá công bằng theo nhóm. Bỏ thuộc tính nhạy cảm không loại được các biến đại diện gián tiếp (thâm niên, cấp bậc); cần đo hiệu năng riêng cho từng nhóm giới tính và tuổi trước khi triển khai.

- Giả định chi phí. Mức hiệu quả can thiệp được đối chiếu với tài liệu, nhưng chi phí can thiệp 1 tháng lương là giả định của nhóm; điểm hòa vốn nên được kiểm chứng bằng thí điểm có đối chứng.
- Không có đơn vị tiền tệ và dữ liệu thị trường, nên chi phí chỉ mang tính tương đối và không so được lương với bên ngoài.

8.3 Hướng mở rộng

- Phân tích sống còn (Kaplan–Meier, Cox) khi có ngày vào làm và ngày nghỉ — trả lời "*khi nào*" nhân viên nghỉ, không chỉ "*ai*".
- Bổ sung dữ liệu lương thị trường và phỏng vấn thôi việc (dạng văn bản) để phân tích bằng NLP.
- Dùng SHAP để giải thích rủi ro ở cấp từng cá nhân, giúp quản lý biết nên trao đổi với nhân viên về vấn đề gì.
- Kiểm tra công bằng theo nhóm (equal opportunity) trước khi triển khai, và thiết kế thí nghiệm A/B cho các chương trình giữ chân.

Tài liệu tham khảo

1. Nguyễn Thu Trang, Hoàng Minh Ngọc, Tạ Bùi Vân Anh, Nguyễn Hoàng Hà Anh & Nguyễn Quang Huy (2026). *Phân tích nghỉ việc IBM HR – Mã nguồn*. Kho GitHub. https://github.com/trangthu171106/ibm-hr-attrition-analysis
2. IBM (2017). *IBM HR Analytics Employee Attrition & Performance* [Dữ liệu]. Kaggle. https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset
3. Nguyễn Quang Huy, Nguyễn Trung Thành và cộng sự (2025). *Khoa học dữ liệu cơ bản trong kinh tế và kinh doanh – Ứng dụng với Python*. Trường Công nghệ, Đại học Kinh tế Quốc dân. https://github.com/NCT-NEU/Sach_Khoa_hoc_du_lieu_python
4. McFeely, S. & Wigert, B. (2019). *This Fixable Problem Costs U.S. Businesses $1 Trillion*. Gallup Workplace. https://www.gallup.com/workplace/247391/fixable-problem-costs-businesses-trillion.aspx
5. McEvoy, G. M. & Cascio, W. F. (1985). Strategies for reducing employee turnover: A meta-analysis. *Journal of Applied Psychology*, 70(2), 342–353.
6. Phillips, J. M. (1998). Effects of realistic job previews on multiple organizational outcomes: A meta-analysis. *Academy of Management Journal*, 41(6), 673–690.
7. Earnest, D. R., Allen, D. G. & Landis, R. S. (2011). Mechanisms linking realistic job previews with turnover: A meta-analytic path analysis. *Personnel Psychology*, 64(4), 865–897.
8. Ribes, E., Touahri, K. & Perthame, B. (2017). *Employee turnover prediction and retention policies design: a case study*. arXiv:1707.01377.
9. Herzberg, F. (1966). *Work and the Nature of Man*. Cleveland: World Publishing.
10. Adams, J. S. (1963). Towards an understanding of inequity. *Journal of Abnormal and Social Psychology*, 67(5), 422–436.
11. Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.